

支持向量机 (SVM)

标签 (空格分隔) : 监督学习

@author : duanxxnj@163.com

@time : 2016-07-31

支持向量机SVM

二软间隔最大化分类器

1 软间隔最大化分类器的两个问题

哪些是分类错误的样本点

分类错误的样本点的处理软间隔变量

2 软间隔最大化分类器 的优化公式

3 软间隔最大化分类器 的对偶问题

4 软间隔最大化分类器 求解

5 对参数 α 的讨论

二、软间隔最大化分类器

在这篇文章之前所有的讨论中, 假设, 所面对的数据在特征空间 $\phi(x)$ 中是线性可分的, 那么, 最终得到的SVM可以在输入空间 X 中得到一个准确的判别面, 尽管其对应的判别面可能是一个非线性判别面。

然而, 在现实的数据中, 数据是线性不可分的 (或者近似线性可分)。换一种说法就是: 类条件分布存在重叠。如果这样, 上面讲的算法最终只会有两种结果: 1、决策面会出现严重的震荡, 而无法收敛; 2、即便收敛到了一个非线性的决策面, 其决策面也会十分的复杂, 泛化能力低。

因此, 我们就需要对原始的SVM算法做一定的改动, 让它对数据的要求, 从线性可分扩展到线性不可分。即: 允许部分训练数据存在分类错误的情况, 以得到一个相对比较好的决策面。这个改动后的SVM一般被称为 **软间隔最大化分类器**, 而与之相对应的, 前面论述的只可以解决线性可分数据的SVM, 称为 **硬间隔最大化分类器**。

2.1 软间隔最大化分类器的两个问题


那么, 现在就有两个问题摆在我们面前:

- 1.在SVM中, 对于非线性可分的数据而言, 哪些样本点是存在分类错误的样本点?
- 2.对于分类错误的点, **软间隔最大化分类器** 如何处理以得到相对比较好的决策面?

两个问题, 就是软间隔最大化分类器的核心问题, 回答了这两个问题, 掌握了软间隔最大化分类器。

哪些是分类错误的样本点

首先必须要知道，面对一个非线性可分的数据集，哪些样本点是分类错误的样本点？可以先看下面这幅图：



图中，左边那幅图对应的是数据线性可分时，SVM的状态。此时有决策面： $x^T \beta + \beta_0 = 0$ ，也就是之前讨论的 $x^T w + b = 0$ ，只是写法不同而已。根据前面“最小间隔最大化”小章节的讨论可知：最小间隔为 $M = 1/\|\beta\|$ ，也就是之前的表达式： $r = 1/\|w\|$ 。这种状态，是所有数据点都分类正确，且最小间隔最大分类的状态。

图中，右边那幅图对应的就是数据线性不可分时，SVM的状态。此时决策面依然是： $x^T \beta + \beta_0 = 0$ ，最小间隔仍然为 $M = 1/\|\beta\|$ 。不过，右图中 ξ_i^* ; $i = 1, 2, \dots, 5$ 就是非线性可分数据在SVM中分类错误的点。

那么总结一下，在非线性可分的情况下，样本点的状态一共有下面五种：

- 1.非支持向量，即是在 margin 两侧，被正确分类的样本点。这些样本点对于SVM的决策面没有贡献。
- 2.在margin边界上面的点，这个是支持向量，且被正确分类。
- 3.在margin内部，被正确分类的点，比如 $\xi_1^*, \xi_2^*, \xi_4^*$ ，这些也是支持向量。
- 4.在决策面上的点，这些点可以拒绝判断，也可以直接认为是分类正确的点。
- 5.真正的被分类错误的点： ξ_3^*, ξ_5^* ，这些点直接走到了决策面的另一边去了。

很容易发现，相对于数据线性可分的情况而言，非线性可分数据的状态多了三种情况，也就是上面五种情况的后三种，线性可分的数据只存在前面两种情况。

而后面三种情况的样本点的间隔，都比最小间隔 r 也就是图中的 M 要小一些，所以，后面这三种情况，就是SVM认为的错误的样本点（即便情况3、情况4样本被分类正确了），**软间隔最大化分类器** 就是要针对后面这三种情况来做文章。

分类错误的样本点的处理:软间隔变量

前面提到了，后面三种情况的样本点的间隔，都比最小间隔 r 也就是图中的 M 要小一些。这里首先要考虑的问题就是，如何用公式来表达后面这三种情况？这里就引入了一个最小间隔 r 的比例因子：软间隔变量 ξ 。 ξ 是最小间隔 r 的比例系数，或者叫做倍数。下面先分别讨论如何将软间隔变量 ξ 应用到上面的后三种情况中：

- 对于前面第三种情况：在margin内部，被正确分类的点，比如 $\xi_1^*, \xi_2^*, \xi_4^*$ 。这些点的间隔为：

$$\begin{aligned} \xi_i^* &= \xi_i * r; & 0 < \xi_i < 1 \\ \xi_i^* &= \xi_i * r; & 0 < \xi_i < 1 \end{aligned}$$

- 对于前面第四种情况：在决策面上的点，这些点的间隔为：

$$\begin{aligned}\xi_i^* &= \xi_i * r; & \xi_i &= 1 \\ \xi_i^* &= \xi_i * r; & \xi_i &= 1\end{aligned}$$

- 对于前面第五种情况：真正的被分类错误的点： $\xi_3^*, \xi_5^*, \xi_3^*, \xi_5^*$ ，这些直接走到了决策面的另一边去了的点，这些点的间隔为：

$$\begin{aligned}\xi_i^* &= \xi_i * r; & \xi_i &> 1 \\ \xi_i^* &= \xi_i * r; & \xi_i &> 1\end{aligned}$$

为了将前面的第一种情况：非支持向量，即是在 margin 两侧，被正确分类的样本点。和第二种情况：在 margin 边界上面的点，这个是支持向量，且被正确分类。也统一的用软间隔变量 ξ_i 来表示，这里将SVM的优化公式重写为下面这个形式：

$$\begin{aligned}\max_{w,b} & r \\ \text{st: } & \frac{t_i \{w^T \phi(x_i) + b\}}{\|w\|} \geq r(1 - \xi_i); \quad i = 1, 2, \dots, N \\ & \xi_i \geq 0; \quad i = 1, 2, \dots, N \\ \max_{w,b} \text{st: } & t_i \{w^T \phi(x_i) + b\} / \|w\| \geq r(1 - \xi_i); \quad i = 1, 2, \dots, N \\ & \xi_i \geq 0; \quad i = 1, 2, \dots, N\end{aligned}$$

而前面第一种情况和第二种情况所对应的 $\xi_i = 0, \xi_i = 0$ 。

和“最小间隔最大化”章节中讨论的一样， w 和 b 的 **比值** 不变的情况下， w 是可以任意取值的。这样的话，为了便于计算，我们就取：

$$\begin{aligned}\|w\| &= \frac{1}{r} \\ \|w\| &= 1/r\end{aligned}$$

那么，上面的式子又可以改写为：

$$\begin{aligned}\max_{w,b} & \frac{1}{\|w\|} \\ \text{st: } & t_i \{w^T \phi(x_i) + b\} \geq 1 - \xi_i; \quad i = 1, 2, \dots, N \\ & \xi_i \geq 0; \quad i = 1, 2, \dots, N \\ \max_{w,b} \text{st: } & t_i \{w^T \phi(x_i) + b\} \geq 1 - \xi_i; \quad i = 1, 2, \dots, N \\ & \xi_i \geq 0; \quad i = 1, 2, \dots, N\end{aligned}$$

可以看到，上面的式子是最大化 $1/\|w\|$ ，很容易知道，其等价于最小化 $\|w\|^2$ ，那么最小间隔最大化，最终就可以变为下面这个式子：

$$\begin{aligned}\min_{w,b} & \|w\|^2 \\ \text{st: } & t_i \{w^T \phi(x_i) + b\} \geq 1 - \xi_i; \quad i = 1, 2, \dots, N \\ & \xi_i \geq 0; \quad i = 1, 2, \dots, N \\ \min_{w,b} \text{st: } & t_i \{w^T \phi(x_i) + b\} \geq 1 - \xi_i; \quad i = 1, 2, \dots, N \\ & \xi_i \geq 0; \quad i = 1, 2, \dots, N\end{aligned}$$

这里，最小间隔为：

$$\begin{aligned}r &= \frac{1}{\|w\|} \\ r &= 1/\|w\|\end{aligned}$$

2.2 软间隔最大化分类器 的优化公式

上面提到的第五种情况，真正的被分类错误的点： $\xi_3^*, \xi_5^*, \xi_3^*, \xi_5^*$ ，这些直接走到了决策面的另一边去了的点，所对应的 $\xi_i > 1, \xi_i > 1$ 。如果说我们知道 $\sum_{i=1}^N \xi_i \leq K, \sum_{i=1}^N \xi_i \leq K$ ，那么，可以说，这个 **软间隔最大化分类器** 的训练错误样本数，最多为 K 个。让训练误差尽量的小也是我们的一个优化目标，这样，**软间隔最大化分类器** 就成了一个多目标的优化问题：

$$\begin{aligned} \min_{w,b} & \frac{1}{2} \|w\|^2 \\ \min_{\xi} & \sum_{i=1}^N \xi_i \\ \text{st: } & t_i \{w^T \phi(x_i) + b\} \geq 1 - \xi_i; i = 1, 2, \dots, N \\ & \xi_i \geq 0; i = 1, 2, \dots, N \end{aligned}$$

$$\min_{w,b,\xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i \quad \text{st: } t_i \{w^T \phi(x_i) + b\} \geq 1 - \xi_i; i = 1, 2, \dots, N, \xi_i \geq 0; i = 1, 2, \dots, N$$

由于上面两个优化目标的限制条件是一样的，可以将两个优化目标合成一个优化目标：

$$\begin{aligned} \min_{w,b,\xi} & \left\{ \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i \right\} \\ \text{st: } & t_i \{w^T \phi(x_i) + b\} \geq 1 - \xi_i; i = 1, 2, \dots, N \\ & \xi_i \geq 0; i = 1, 2, \dots, N \end{aligned}$$

$$\min_{w,b,\xi} \left\{ \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i \right\} \quad \text{st: } t_i \{w^T \phi(x_i) + b\} \geq 1 - \xi_i; i = 1, 2, \dots, N, \xi_i \geq 0; i = 1, 2, \dots, N$$

这里的参数 C 是损失参数 (cost parameter)，用于权衡 $\|w\|^2$ 和 $\sum_{i=1}^N \xi_i$ 。一般我们将 $\|w\|^2$ 视为模型的复杂度，而将 $\sum_{i=1}^N \xi_i$ 视为模型的错误率，损失参数 C 就是在模型复杂度和模型的错误率之间找一个平衡，这个值一般作为模型的一个输入变量，需要人工设置：

- C 越小，模型越偏向于最小化 $\|w\|^2$ ，而忽略 $\sum_{i=1}^N \xi_i$ ，这样模型非常简单，但模型的错误率相对较高。
- C 越大，模型越偏向于最小化 $\sum_{i=1}^N \xi_i$ ，而忽略 $\|w\|^2$ ，这样模型的错误率相对较低，但模型相对较为复杂。

需要强调： ξ_i 是对于 SVM 而言，分类错误的样本点 x_i 的分类错误间隔相对于最小间隔 r 的比例。我们不可能让错误的比例无限的增长，那样分类错误就太大了。所以，我们需要对错误间隔进行限制，而限制的手段，就是为总的错误间隔比例加一上限： $\sum \xi_i \leq \text{constant}$ 。这是 **软间隔最大化分类器** 优化公式的另一种解释。

2.3 软间隔最大化分类器的对偶问题

这里的步骤和 1.5 拉格朗日对偶性 几乎雷同，首先将 **软间隔最大化分类器** 的优化公式转换为拉格朗日函数的形式，其原始的优化公式为：

$$\begin{aligned} \min_{w,b,\xi} & \left\{ \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i \right\} \\ \text{st: } & t_i \{w^T \phi(x_i) + b\} \geq 1 - \xi_i; i = 1, 2, \dots, N \\ & \xi_i \geq 0; i = 1, 2, \dots, N \end{aligned}$$

$$\min_{w,b,\xi} \left\{ \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i \right\} \quad \text{st: } t_i \{w^T \phi(x_i) + b\} \geq 1 - \xi_i; i = 1, 2, \dots, N, \xi_i \geq 0; i = 1, 2, \dots, N$$

拉格朗日函数为：

$$L(w, b, \xi, \alpha, \mu) = \underbrace{\frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i}_{\text{优化目标}} - \underbrace{\sum_{i=1}^N \alpha_i \{t_i \{w^T \phi(x_i) + b\} - 1 + \xi_i\} - \sum_{i=1}^N \mu_i \xi_i}_{\text{不等式约束}}$$

$$L(w, b, \xi, \alpha, \mu) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i - \sum_{i=1}^N \alpha_i \{t_i \{w^T \phi(x_i) + b\} - 1 + \xi_i\} - \sum_{i=1}^N \mu_i \xi_i$$

其中, α_i, μ_i 为拉格朗日乘子。将 $L(w, b, \xi, \alpha, \mu)$ 分别对 w, b, ξ 求偏导:

$$\nabla_w L(w, b, \xi, \alpha, \mu) = w - \sum_{i=1}^N \alpha_i t_i \phi(x_i) = 0$$

$$\nabla_b L(w, b, \xi, \alpha, \mu) = \sum_{i=1}^N \alpha_i t_i = 0$$

$$\nabla_{\xi_i} L(w, b, \xi, \alpha, \mu) = C - \alpha_i - \beta_i = 0; i = 1, 2, \dots, N$$

$$\nabla_w L(w, b, \xi, \alpha, \mu) = w - \sum_{i=1}^N \alpha_i t_i \phi(x_i) = 0 \quad \nabla_b L(w, b, \xi, \alpha, \mu) = \sum_{i=1}^N \alpha_i t_i = 0 \quad \nabla_{\xi_i} L(w, b, \xi, \alpha, \mu) = C - \alpha_i - \beta_i = 0; i = 1, 2, \dots, N$$

就可以得到:

$$w = \sum_{i=1}^N \alpha_i t_i \phi(x_i)$$

$$\sum_{i=1}^N \alpha_i t_i = 0$$

$$C - \alpha_i - \beta_i = 0; i = 1, 2, \dots, N$$

$$w = \sum_{i=1}^N \alpha_i t_i \phi(x_i) \quad \sum_{i=1}^N \alpha_i t_i = 0 \quad C - \alpha_i - \beta_i = 0; i = 1, 2, \dots, N$$

将上面三个式子带入到 $L(w, b, \xi, \alpha, \mu)$ 中, 和之前 1.6 最小间隔最大化求解 中的推导一样, 最终可以得到:

$$\min_{w, b, \xi} L(w, b, \xi, \alpha, \mu) = -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \{\alpha_i \alpha_j t_i t_j < \phi(x_i), \phi(x_j) >\} + \sum_{i=1}^N \alpha_i$$

$$\min_{w, b, \xi} L(w, b, \xi, \alpha, \mu) = -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \{\alpha_i \alpha_j t_i t_j < \phi(x_i), \phi(x_j) >\} + \sum_{i=1}^N \alpha_i$$

这里的 $< \phi(x_i), \phi(x_j) >$ 是 $\phi(x_i)$ 和 $\phi(x_j)$ 的内积。

再对 $\min_{w, b, \xi} L(w, b, \xi, \alpha, \mu)$ 求极大化, 即可得到 **软间隔最大化分类器** 的对偶问题:

$$\max_{\alpha} \left\{ -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \{\alpha_i \alpha_j t_i t_j < \phi(x_i), \phi(x_j) >\} + \sum_{i=1}^N \alpha_i \right\}$$

$$\max_{\alpha} \left\{ -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \{\alpha_i \alpha_j t_i t_j < \phi(x_i), \phi(x_j) >\} + \sum_{i=1}^N \alpha_i \right\}$$

$$\text{s.t. } \sum_{i=1}^N \alpha_i t_i = 0$$

$$C - \alpha_i - \mu_i = 0$$

$$\alpha_i \geq 0$$

$$\mu_i \geq 0; i = 1, 2, \dots, N$$

$$\text{s.t. } \sum_{i=1}^N \alpha_i t_i = 0 \quad C - \alpha_i - \mu_i = 0 \quad \alpha_i \geq 0 \quad \mu_i \geq 0; i = 1, 2, \dots, N$$

这个就是原问题的对偶问题, 当然了, 可以将这个对偶问题的目标函数的符号换一下, 让它成为一个最小化的问题, 并将后面三个式子做一个合并:

$$\min_{\alpha} \left\{ \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \{\alpha_i \alpha_j t_i t_j < \phi(x_i), \phi(x_j) >\} - \sum_{i=1}^N \alpha_i \right\}$$

$$\min_{\alpha} \left\{ \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \{\alpha_i \alpha_j t_i t_j < \phi(x_i), \phi(x_j) >\} - \sum_{i=1}^N \alpha_i \right\}$$

$$\text{s.t. } \sum_{i=1}^N \alpha_i t_i = 0$$

$$0 \leq \alpha_i \leq C; i = 1, 2, \dots, N$$

$$\text{s.t. } \sum_{i=1}^N \alpha_i t_i = 0 \quad 0 \leq \alpha_i \leq C; i = 1, 2, \dots, N$$

这就是 **软间隔最大化分类器** 的对偶问题，和前面相比，这里的对偶问题只是限制条件 $0 \leq \alpha_i \leq C$ $0 \leq \alpha_i \leq C$ 和前面不同，其他的是一模一样的。

2.4 软间隔最大化分类器 求解

很显然，得到了**软间隔最大化分类器**的对偶形式之后，其优化求解出来的就是最优解 α^* 。这里再次说明：假设 α^* 我们已经通过某种算法得到了，至于这个算法是什么后面的章节会详细的说明，这里不用担心。

仿照 1.5 拉格朗日对偶性 中的公式推导，假设 $x^*, \alpha^*, \xi^*, \alpha^*, \mu^*$ 为最优解，可以很容易推出 **软间隔最大化分类器** 拉格朗日优化的KKT条件为：

$$\nabla_w L(x^*, \alpha^*, \xi^*, \alpha^*, \mu^*) = w^* - \sum_{i=1}^N \alpha_i^* t_i \phi(x_i) = 0$$

$$\nabla_b L(x^*, \alpha^*, \xi^*, \alpha^*, \mu^*) = \sum_{i=1}^N \alpha_i^* t_i = 0$$

$$\nabla_{\xi} L(x^*, \alpha^*, \xi^*, \alpha^*, \mu^*) = C - \alpha_i - \mu_i = 0$$

$$\alpha_i^* (t_i \{w^{*T} \phi(x_i) + b^*\} - 1 + \xi_i^*) = 0; i = 1, 2, \dots, N$$

$$t_i \{w^{*T} \phi(x_i) + b^*\} - 1 + \xi_i^* \geq 0; i = 1, 2, \dots, N$$

$$\alpha_i^* \geq 0; i = 1, 2, \dots, N$$

$$\mu_i^* \xi_i^* = 0; i = 1, 2, \dots, N$$

$$\xi_i^* \geq 0; i = 1, 2, \dots, N$$

$$\mu_i^* \geq 0; i = 1, 2, \dots, N$$

$$\nabla_w L(x^*, \alpha^*, \xi^*, \alpha^*, \mu^*) = w^* - \sum_{i=1}^N \alpha_i^* t_i \phi(x_i) = 0 \quad \nabla_b L(x^*, \alpha^*, \xi^*, \alpha^*, \mu^*) = \sum_{i=1}^N \alpha_i^* t_i = 0 \quad \nabla_{\xi} L(x^*, \alpha^*, \xi^*, \alpha^*, \mu^*) = C - \alpha_i - \mu_i = 0$$

$$\alpha_i^* (t_i \{w^{*T} \phi(x_i) + b^*\} - 1 + \xi_i^*) = 0; i = 1, 2, \dots, N$$

$$t_i \{w^{*T} \phi(x_i) + b^*\} - 1 + \xi_i^* \geq 0; i = 1, 2, \dots, N$$

$$\alpha_i^* \geq 0; i = 1, 2, \dots, N$$

$$\mu_i^* \xi_i^* = 0; i = 1, 2, \dots, N$$

$$\xi_i^* \geq 0; i = 1, 2, \dots, N$$

$$\mu_i^* \geq 0; i = 1, 2, \dots, N$$

在假设知道 α^* 的情况下，由 KKT 条件的第一个公式： $\nabla_w L(x^*, \alpha^*, \xi^*, \alpha^*, \mu^*) = w^* - \sum_{i=1}^N \alpha_i^* t_i \phi(x_i) = 0$ 可以知道， w^* 的最优解为：

$$w^* = \sum_{i=1}^N \alpha_i^* t_i \phi(x_i)$$

$$w^* = \sum_{i=1}^N \alpha_i^* t_i \phi(x_i)$$

再找到一个 $0 < \alpha_j < C$ $0 < \alpha_j < C$ ，其所对应的样本点满足： $t_i \{w^{*T} \phi(x_i) + b^*\} - 1 = 0$ $t_i \{w^{*T} \phi(x_i) + b^*\} - 1 = 0$ ，那么，就可以和前面的推导一样，得到：

$$b^* = \frac{1}{t_i} - w^{*T} \phi(x_i)$$

$$b^* = 1 - t_i w^{*T} \phi(x_i)$$

同时，需要注意： $t_i^2 = 1$ $t_i^2 = 1$ ，并带入 $w^{*T} w^* = 1$ ，就可以将上面这个式子重写为：

$$b^* = t_i - \sum_{j=1}^N \alpha_j^* t_j \langle \phi(x_j), \phi(x_i) \rangle$$

$$b^* = t_i - \sum_{j=1}^N \alpha_j^* t_j \langle \phi(x_j), \phi(x_i) \rangle$$

当然，为了稳妥起见，很多时候，我们会将所有支持向量 $x_i \in S$ $x_i \in S$ 对应的 b_i^* b_i^* 都求出来，然后用其均值，作为最终的 b^* 。这里 S 是支持向量的集合，也就是 $\alpha_i^* > 0$ $\alpha_i^* > 0$ 所对应的点集：

$$b^* = \frac{1}{N_s} \sum_{i=1}^{N_s} b_i^*$$

$$b^* = 1/N \sum_{i=1}^N b_i^*$$

这样，就可以求得最终的决策超平面为：

$$\sum_{i=1}^N \{\alpha_i^* t_i < \phi(x_i), \phi(x) >\} + b^* = 0$$

$$\sum_{i=1}^N \{\alpha_i^* t_i < \phi(x_i), \phi(x) >\} + b^* = 0$$

分类决策函数可以写为：

$$f(x) = \text{sign}\left\{\sum_{i=1}^N \{\alpha_i^* t_i < \phi(x_i), \phi(x) >\} + b^*\right\}$$

$$f(x) = \text{sign}\left\{\sum_{i=1}^N \{\alpha_i^* t_i < \phi(x_i), \phi(x) >\} + b^*\right\}$$

2.5 对参数 α, ξ, ξ 的讨论

基于上面的推导，可以很容易的看出，**软间隔最大化分类器**就是在**硬间隔最大化分类器**的基础上，处理非线性可分的数据。而参数 α, ξ, ξ 起着决定样本点类别的作用，那么，这里就对这两个参数做一下讨论，看看这两个参数是如何判断非线性可分数据集中的样本点的类别的。

为了方便，这里直接用一张表格说明参数 α, ξ, ξ 和样本点之间的关系，图中叉叉的部分，说明这种情况并不存在，下面将对这个表格做详细的说明：

		分类正确的点			分类错误的点
		$\xi = 0$	$0 < \xi < 1$	$\xi = 1$	$\xi > 1$
α	ξ				
不是支持向量	$\alpha = 0$	非支持向量 对决策面没有贡献			
是支持向量	$0 < \alpha < C$	支持向量 在SVM边界上			
	$\alpha = C$		支持向量 在SVM正确边界内	支持向量 在SVM超平面上	支持向量 分类错误点

在 2.1 软间隔最大化分类器的两个问题 中，就讨论过，非线性可分情况下，SVM中的样本点一共有五种情况，也就是上面表格中的所对应的五种情况。

从表格中可以粗略的观察到：

- 当 $\alpha_i = 0$ 时，对应的样本点是支持向量；当 $\alpha_i > 0$ 时，对应的样本点是支持向量
- 当 $\xi \leq 1$ 时，对应的样本点可以被正确的分类；当 $\xi > 1$ 时，对应的样本点分类错误

现在基于参数 α, ξ, ξ 对上面五种情况再做更详细的讨论：

1. 当 $\xi_i = 0, \alpha_i = 0$ 时，此时的样本点 x_i 并不是支持向量，其被完全的分类正确，样本点满足：
 $t_i \{w^T \phi(x_i) + b\} > 1$

变量关系：当 $\alpha_i = 0$ 时，由KKT条件中的第三条： $C - \alpha_i - \mu_i = 0$ 可以知道， $\mu_i = C$ ；再由KKT条件第七条： $\mu_i^* \xi_i^* = 0$ 可以知道： $\xi_i = 0$ ；最后根据KKT条件的第四条和第五条，可以很容易知道：
 $t_i \{w^T \phi(x_i) + b\} > 1$

2. 当 $\xi_i = 0, 0 < \alpha_i < C$ 时, 此时样本点刚好在SVM的间隔边界上, 是支持向量, 被正确分类, 样本点满足: $t_i \{w^T \phi(x_i) + b\} = 1$ 。

变量关系: 当 $0 < \alpha_i < C$ 时, 由KKT条件中的第三条: $C - \alpha_i - \mu_i = 0$ 可以知道, $0 < \mu_i < C$; 再由KKT条件第七条: $\mu_i^* \xi_i^* = 0$, 可以知道: $\xi_i = 0$ 。最后根据KKT条件的第四条和第五条, 可以很容易知道: $t_i \{w^T \phi(x_i) + b\} = 1$ 。

3. 当 $0 < \xi_i < 1, \alpha_i = C$ 时, 此时样本点在SVM的正确的间隔边界内, 是支持向量, 被正确分类, 样本点满足: $0 < t_i \{w^T \phi(x_i) + b\} < 1$ 。

变量关系: 当 $\alpha_i = C$ 时, 由KKT条件中的第三条: $C - \alpha_i - \mu_i = 0$ 可以知道, $\mu_i = 0$; 再由KKT条件第六、七条: $\xi_i^* \geq 0; \mu_i^* \xi_i^* = 0$, 可以知道: $\xi_i > 0$ 。根据KKT条件的第四条和第五条, 可以很容易知道: $t_i \{w^T \phi(x_i) + b\} = 1 - \xi_i$ 。那么, 此时 $0 < \xi_i < 1$, 所以 $0 < t_i \{w^T \phi(x_i) + b\} < 1$, 即, 其对应的样本点在分类正确的间隔中。

4. 当 $\xi_i = 1, \alpha_i = C$ 时, 此时样本点在SVM决策面上, 是支持向量, 被正确分类, 样本点满足: $t_i \{w^T \phi(x_i) + b\} = 0$ 。

变量关系: 这里的变量关系的分析和第三种情况一样, 差别仅仅是 $\xi_i = 1$, 由: $t_i \{w^T \phi(x_i) + b\} = 1 - \xi_i$, 可以很容易知道: $t_i \{w^T \phi(x_i) + b\} = 0$, 这样, 样本点 x_i 就刚好在SVM的决策面上了。

5. 当 $\xi_i > 1, \alpha_i = C$ 时, 是支持向量, 被错误分类, 样本点满足: $t_i \{w^T \phi(x_i) + b\} < 0$ 。

变量关系: 这里的变量关系的分析和第三种情况一样, 差别仅仅是 $\xi_i > 1$, 由: $t_i \{w^T \phi(x_i) + b\} = 1 - \xi_i$, 可以很容易知道: $t_i \{w^T \phi(x_i) + b\} < 0$, 这样, 样本点 x_i 就在决策面错误的一边, 被错误分类了。

由于变量 α 是我们最终要求解的变量, 这里再单独对变量 α 做一个总结。首先, 这里取 $g(x)$ 如下, 即SVM的决策面函数:

$$g(x) = \sum_{i=1}^N \{\alpha_i t_i < \phi(x_i), \phi(x) >\} + b$$

$$g(x) = \sum_{i=1}^N \{\alpha_i t_i < \phi(x_i), \phi(x) >\} + b$$

那么, 根据前面的表格, 可以很容易得到:

$$\begin{aligned} \alpha_i = 0 &\Leftrightarrow t_i g(x_i) \geq 1 \\ 0 < \alpha_i < C &\Leftrightarrow t_i g(x_i) = 1 \\ \alpha_i = C &\Leftrightarrow t_i g(x_i) \leq 1 \\ \alpha_i = 0 &\Leftrightarrow t_i g(x_i) \geq 1 \\ 0 < \alpha_i < C &\Leftrightarrow t_i g(x_i) = 1 \\ \alpha_i = C &\Leftrightarrow t_i g(x_i) \leq 1 \end{aligned}$$

总的来说就是:

- 在SVM间隔区间外的点, 对应的 $\alpha_i = 0$
- 在SVM间隔区间边缘上的点, 对应的 $0 < \alpha_i < C$
- 在SVM间隔区间内部的点, 对应的 $\alpha_i = C$