



悲催的袜子

悲催的袜子
(<http://sadsock.leanote.com>)

码农，飞蚊症患者，不想活了

图像分割算法之Graph Cut

图像处理 (<http://sadsock.leanote.com/tag/图像处理>)

图像分割 (<http://sadsock.leanote.com/tag/图像分割>)


所谓科研 (<http://sadsock.leanote.com/tag/所谓科研>)

0 0

2017-03-18 07:19:43 407

概述

这篇博客是笔者学习 **graph cut** 时的笔记，主要记录了 **graph cut** 的概念和如何为一副已知图像建立对应的graph。主要参考了文章 **Image segmentation: A survey of graph-cut methods** .



图像分割问题转化为能量函数最小化问题

图像分割可以被当做一个像素分类问题，前景像素被标记为1类，背景像素被标记为0类。显然，一个好图像分割，割边应该都位于前景和背景的分界处。

令 $L = \{l_1, l_2, l_3, \dots, l_i, \dots, l_p\}$ ，其中 p 是像素的数量， $l_i \in \{0, 1\}$ 。也就是说，集合 L 中的元素根据取值可以分为两类，取值为1的组成前景，取值为0的组成背景。定义如下的能量函数

$$E(L) = \alpha R(L) + B(L) \quad (1)$$

其中， $R(L)$ 被成为区域项，用来描述区域内部的点的是同一类的概率； $B(L)$ 被称为边界项，用来描述边界上的点不属于同一类的概率； α 是权重因子，用来控制边界项和区域项的相对重要程度。当 α 被设置为0时，区域项就被忽略了，只有边界项影响分割结果。

在能量方程 (1) 中，区域项通常被定义为

$$R(L) = \sum_{p \in P} R_p(l_p) \quad (2)$$

其中， $R_p(l_p)$ 是把标签 l_p 分配给像素 p 的惩罚，一个获取 $R_p(l_p)$ 的简单办法就是把像素 p 的颜色值与背景或者前景的颜色直方图进行比较。 $R_p(l_p)$ 通常定义如下

$$R_p(1) = -\ln \Pr(I_p | 'obj') \quad (3)$$

$$R_p(0) = -\ln \Pr(I_p | 'bkg') \quad (4)$$

根据公式(3)和公式(4)，当 $\Pr(I_p | 'obj')$ 大于 $\Pr(I_p | 'bkg')$ 时， $R_p(1)$ 小于 $R_p(0)$ 。这就是说，当像素被正确分类时，惩罚项的值变小，能量函数的值也会变小。因此，当所有像素都被正确分类时，区域项应该取得最小值。

边界项通常定义如下

$$B(L) = \sum_{\{p,q\} \in E} B_{\langle p,q \rangle} \delta(l_p, l_q) \quad (5)$$

其中， p, q 是相邻像素， $\delta(l_p, l_q)$ 被定义如下

$$\delta(l_p, l_q) = \begin{cases} 0 & l_p = l_q \\ 1 & l_p \neq l_q \end{cases} \quad (6)$$

在这一定义下， $B(L)$ 实际上就是分割边界两侧的像素的相似度的一种测量。 $B_{\langle p,q \rangle}$ 通常定义为 $|p - q|$ 的递减函数， p 和 q 表示像素的颜色值，例如

$$B_{\langle p,q \rangle} \propto \exp\left(-\frac{(I_p - I_q)^2}{2\sigma^2}\right) \quad (7)$$



悲催的袜

悲催的袜子
(<http://sadsock.leanote.com>)

码农，飞蚊症患者，不想活了


从 $B(L)$ 的定义可以看出，边界两侧的点差距越大， $B(L)$ 的取值就越小，当每个像素都被合理的分类时 $B(L)$ 也应该取得最小值。

最小割与最大流

给定一个无向图 $G = \langle V, E \rangle$ ，其中 V 是顶点， E 是连接相邻顶点的边。顶点分为两种，一种是内部点，通常与图像中的像素一一对应；另一种是终结点，终结点有两个，一个叫源点 s ，一般表示图像的前景，一个叫汇点 t ，一般表示图像的背景。图中的边也分为两种，内部节点之间的边被称为n-links；内部节点与终结点之间的边被称为t-links。这种图通常被称作 $s-t$ 图。图中的每一条边都有一个非负权重 w_e ，被称为代价。图割 C 定义为边集 E 的一个子集，当把图中所有属于 C 的边删除后，图 G 被分成两个不相交的联通子图 $G_0 = \langle S, E_0 \rangle$ 和 $G_1 = \langle T, E_1 \rangle$ ，其中 $s \in S, t \in T$ 并且满足 $S \cup T = V, C \cup E_0 \cup E_1 = E$ 。这两个子集一个对应为图像的前景，另一个对应于图像的背景。图割的代价 $|C|$ 就是边集 C 中所有边的代价之和。也就是说

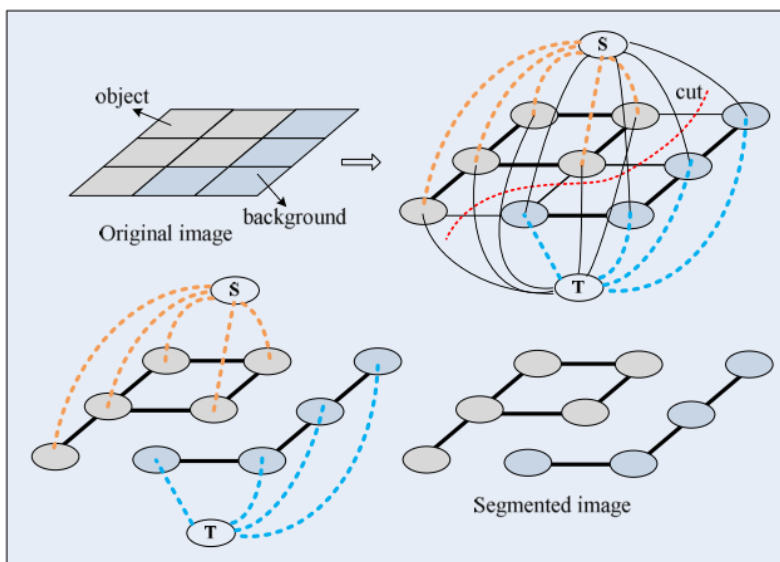
$$|C| = \sum_{e \in C} w_e \quad (8)$$

代价最小的图割，就是最小割。对于 $s-t$ 图，求最小割就等于求最大流，因此求最小割的算法也叫max-flow/min-cut（最大流最小割）算法。



最小割与能量函数最小化的关系

Boykov 和 Jolly已经证明，当 $s-t$ 中边的权重按照公式(9)所示的方式设置时， $s-t$ 图的每一种图割与能量函数(1)的每一种取值一一对应， $s-t$ 的最小割也就对应(1)的最小值。因此，求能量函数(1)的最小值，就是求 $s-t$ 的最小割，而求 $s-t$ 图的最小割就是求 $s-t$ 图的最大流





悲催的袜子

悲催的袜子 (<http://sadsock.leanote.com>)

码农，飞蚊症患者，不想活了

上一篇: Multi-Class Segmentation with Relative Location Prior
(<http://sadsock.leanote.com/post/Multi-Class-Segmentation-with-Relative-Location-Prior>)

下一篇: 超像素分割之LSC (<http://sadsock.leanote.com/post/73026d8ecf49>)

0 赞

407 人读过

新浪微博

微信



立即登录, 发表评论.
没有帐号? 立即注册

0 条评论

导航

主页 (<http://sadsock.leanote.com>)
程序人生 (<http://sadsock.leanote.com/cate/%E7%BC%96%E7%A8%8B>)
所谓科研 (<http://sadsock.leanote.com/cate/study>)
About Me (<http://sadsock.leanote.com/single/About-Me>)
归档 (<http://sadsock.leanote.com/archives>)
标签 (<http://sadsock.leanote.com/tags>)

最近发表

超像素分割之FLIC (<http://sadsock.leanote.com/post/4928c87471b8>)
非对称高斯模型 (<http://sadsock.leanote.com/post/7195eff546a0>)
EM和K-MEANS的关系 (<http://sadsock.leanote.com/post/c81d5360855b>)
clustering ensembles: models of consensus and weak partitions
(<http://sadsock.leanote.com/post/%E8%81%9A%E7%B1%BBs>)
聚类算法之 Combining Multiple Clusterings Using Evidence Accumulation
(<http://sadsock.leanote.com/post/b8267e76896e>)

友情链接

My Note (<https://leanote.com/note>)
Leanote Home (<https://leanote.com>)
Leanote BBS (<http://bbs.leanote.com>)
Leanote Github (<https://github.com/leanote/leanote>)

Proudly powered by Leanote (<https://leanote.com>)