

# 认知计算、机器人定位导航算法、运筹学算法

理解算法，理解别人的代码，自己写出好程序~~

新随笔 联系 管理

## (一)：细说贝叶斯滤波：Bayes filters

本文为原创文章，转载请注明出处：<http://www.cnblogs.com/ycwang16/p/5995702.html>

认知计算，还要从贝叶斯滤波的基本思想讲起。这一部分，我们先回顾贝叶斯公式的数学基础，然后再来介绍贝叶斯滤波器。

### (一). 概率基础回顾

我们先来回顾一下概率论里的基本知识：

1.  $X$ ：表示一个**随机变量**，如果它有有限个可能的取值 $\{x_1, x_2, \dots, x_n\}$ .
2.  $p(X = x_i)$ ：表示变量 $X$ 的值为 $x_i$ 的**概率**。
3.  $p(\cdot)$ ：称为**概率质量函数(probability mass function)**。

**例如：**一个家里有3个房间，机器人在各个房间的概率为 $p(\text{room}) = \{0.1, 0.3, 0.6\}$ 。

4. 如果 $X$ 在连续空间取值， $p(x)$ 称为**概率密度函数(probability density function)**,

$$p(x \in (a, b)) = \int_a^b p(x) dx$$




图1. 概率密度函数曲线示例

5. **联合概率：** $p(X = x \text{ and } Y = y) = p(x, y)$ ，称为联合概率密度分布。如果 $X$ 和 $Y$ 是相互独立的随机变量， $p(x, y) = p(x)p(y)$ 。
6. **条件概率：** $p(X = x | Y = y)$ 是在已知 $Y = y$ 的条件下，计算 $X = x$ 的概率。

$$p(x|y) = p(x, y)/p(y)$$

$$p(x, y) = p(x|y)p(y) = p(y|x)p(x)$$

如果 $x$ 和 $y$ 相互独立，则：

$$p(x|y) = p(x)$$

### 7. 全概率公式：

离散情况下：

$$p(x) = \sum_y p(x, y) = \sum_y p(x|y)p(y)$$

连续情况下：

$$p(x) = \int p(x, y) dy = \int p(x|y)p(y) dy$$

2018年11月						
<	日	一	二	三	四	五
	28	29	30	31	1	2
	4	5	6	7	8	9
	11	12	13	14	15	16
	18	19	20	21	22	23
	25	26	27	28	29	30
	2	3	4	5	6	7

#### 最新随笔

1. (二). 细说Kalman滤波：The Kalman Filter
2. (一)：细说贝叶斯滤波：Bayes filters
3. 写一个普适计算（认知计算）课程的博客

#### 我的标签

机器人(2)  
认知计算(2)  
条件概率(1)  
条件推理(1)  
信号处理(1)  
Bayes Filter(1)  
bayes滤波(1)  
kalman滤波(1)  
贝叶斯公式(1)  
贝叶斯滤波(1)  
更多

#### 随笔分类

认知计算(3)

#### 阅读排行榜

1. (二). 细说Kalman滤波：The Kalman Filter(5522)
2. (一)：细说贝叶斯滤波：Bayes filters (5005)
3. 写一个普适计算（认知计算）课程的博客(393)

## (二). 贝叶斯公式

### 2.1 贝叶斯公式

基于条件概率公式和全概率公式，我们可以导出贝叶斯公式：

$$\begin{aligned} P(x, y) &= P(x|y)P(y) = P(y|x)P(x) \\ &\Rightarrow \\ P(x|y) &= \frac{P(y|x)P(x)}{P(y)} = \frac{\text{causal knowledge} \cdot \text{prior knowledge}}{\text{prior knowledge}} \end{aligned}$$

- 这里面 $x$ 一般是某种状态； $y$ 一般是代表某种观测。
- 我们称 $P(y|x)$ 为**causal knowledge**，意即由 $x$ 的已知情况，就可以推算 $y$ 发生的概率，例如在图2的例子中，已知如果门开着，则 $z = 0.5m$ 的概率为0.6；如果门关着，则 $z = 0.5m$ 的概率为0.3。
- 我们称 $P(x)$ 为**prior knowledge**，是对 $x$ 的概率的先验知识。例如在图2的例子中，可设门开或关的概率各占50%。
- $P(x|y)$ 是基于观测对状态的诊断或推断。**贝叶斯公式的本质就是利用causal knowledge和prior knowledge来进行状态推断或推理。**

例1: 🤖:

在图2所示的例子中，机器人根据观测的到门的距离，估算门开或关的概率，若测量到门的距离为 $z = 0.5m$ ，则可用条件概率描述门开着的概率：

$$P(\text{open}|z = 0.6) = ?$$




图 2. 机器人根据观测计算门开或关的概率

$$\begin{aligned} P(\text{open}|z = 0.5) &= \frac{P(z|\text{open})P(\text{open})}{P(z)} &< \text{--- 贝叶斯公式} \\ &= \frac{P(z|\text{open})P(\text{open})}{P(z|\text{open})p(\text{open}) + P(z|\neg\text{open})p(\neg\text{open})} &< \text{--- 全概率公式} \\ &= \frac{0.6 \cdot 0.5}{0.6 \cdot 0.5 + 0.3 \cdot 0.5} = 2/3 \end{aligned}$$

### 2.2 贝叶斯公式的计算

可以看到贝叶斯公式的分母项 $P(y)$ ，同 $P(x|y)$ 无关，所以可以把它作为归一化系数看待：

$$\begin{aligned} P(x|y) &= \frac{P(y|x)P(x)}{P(y)} = \eta P(y|x)P(x) \\ \eta &= P(y)^{-1} = \frac{1}{\sum_x P(y|x)P(x)} \end{aligned}$$

所以基于**causal knowledge**和**prior knowledge**进行条件概率计算的过程如下：

**Algorithm:**

$$\forall x : \text{aux}_{x|y} = P(y|x)P(x)$$

$$\eta = \frac{1}{\sum_x \text{aux}_{x|y}}$$

$$\forall x : P(x|y) = \eta \text{aux}_{x|y}$$

### 2.3 贝叶斯公式中融合多种观测

在很多应用问题中，我们会用多种观测信息对一个状态进行猜测和推理，贝叶斯公式中是如何融合多种观测的呢？

我们简单推导一下：

$$\begin{aligned}P(x|y, z) &= \frac{P(x, y, z)}{P(y, z)} \\&= \frac{P(y|x, z)p(x, z)}{P(y, z)} \\&= \frac{P(y|x, z)p(x|z)p(z)}{P(y|z)p(z)} \\&= \frac{P(y|x, z)p(x|z)}{P(y|z)}\end{aligned}$$

所以有：

$$P(x|y, z) = \frac{P(y|x, z) P(x|z)}{P(y|z)}$$

### 2.4 贝叶斯递推公式

由此，我们来推导贝叶斯滤波的递推公式：

$$P(x|z_1, \dots, z_n) = ?$$

我们把 $z_n$ 看做 $y$ ，把 $z_1, \dots, z_{n-1}$ 看做 $z$ ，代入上面的公式：

$$P(x|z_1, \dots, z_n) = \frac{P(z_n|x, z_1, \dots, z_{n-1}) P(x|z_1, \dots, z_{n-1})}{P(z_n|z_1, \dots, z_{n-1})}$$

再由Markov属性，在 $x$ 已知的情况下， $z_n$ 同 $\{z_1, \dots, z_{n-1}\}$ 无关，所以：

$$\begin{aligned}P(x|z_1, \dots, z_n) &= \frac{P(z_n|x, z_1, \dots, z_{n-1}) P(x|z_1, \dots, z_{n-1})}{P(z_n|z_1, \dots, z_{n-1})} \\&= \frac{P(z_n|x) P(x|z_1, \dots, z_{n-1})}{P(z_n|z_1, \dots, z_{n-1})}\end{aligned}$$

从而我们得到贝叶斯的递推公式：

$$\begin{aligned}P(x|z_1, \dots, z_n) &= \frac{P(z_n|x) P(x|z_1, \dots, z_{n-1})}{P(z_n|z_1, \dots, z_{n-1})} \\&= \eta_n P(z_n|x) P(x|z_1, \dots, z_{n-1}) \\&= \eta_n P(z_n|x) \eta_{n-1} P(z_{n-1}|x) P(x|z_1, \dots, z_{n-2}) \\&= \eta_1 \cdots \eta_n \prod_{i=1 \dots n} P(z_i|x) P(x)\end{aligned}$$

例2: 🐶在例1的基础上，如果机器人第二次测量到门的距离仍然为0.5米，计算门开着的概率。

$$\begin{aligned}P(open|z_2, z_1) &= \frac{P(z_2|open) P(open|z_1)}{P(z_2|open) P(open|z_1) + P(z_2|\neg open) P(\neg open|z_1)} \\&= \frac{0.6 \cdot \frac{2}{3}}{0.6 \cdot \frac{2}{3} + 0.3 \cdot \frac{1}{3}} = \frac{0.4}{0.5} = 0.8\end{aligned}$$

所以，第二次 $z=0.5m$ 的观测增大了对门开着的概率的置信程度。

### (三). 如何融入动作？

在实际问题中，对象总是处在一个动态变化的环境中，例如：

1. 机器人自身的动作影响了环境状态
2. 其它对象，比如人的动作影响了环境状态
3. 或者就是简单的环境状态随着时间发生了变化。

如何在Bayes模型中来描述动作的影响呢？

1. 首先，动作所带来的影响也总是具有不确定性的
2. 其次，相比于观测，动作一般会使得对象的状态更为模糊（或更不确定）。

我们用 $u$ 来描述动作，在 $x'$ 状态下，执行了动作 $u$ 之后，对象状态改变为 $x$ 的概率表述为：

$$P(x|u, x')$$

动作对状态的影响一般由状态转移模型来描述。如图3所示，表示了“关门”这个动作对状态影响的转移模型。这个状态转移模型表示：关门这个动作有0.1的失败概率，所以当门是open状态时，执行“关门”动作，门有0.9的概率转为closed状态，有0.1的概率保持在open状态。门是closed的状态下，执行“关门”动作，门仍然是关着的。




图3. “关门”动作的状态转移模型

执行某一动作后，计算动作后的状态概率，需要考虑动作之前的各种状态情况，把所有情况用全概率公式计算：

- 连续情况下：

$$P(x|u) = \int P(x|u, x')P(x')dx'$$

- 离散情况下：

$$P(x|u) = \sum P(x|u, x')P(x')$$

例3: 🐶 在例2的基础上，如果按照图3所示的状态转移关系，机器人执行了一次关门动作，计算动作后门开着的概率？

$$\begin{aligned} P(open|u) &= \sum P(open|u, x')P(x') \\ &= P(open|u, open)P(open) \\ &\quad + P(open|u, closed)P(closed) \\ &= \frac{1}{10} * 0.8 + \frac{0}{1} * 0.2 = 0.08 \\ P(closed|u) &= \sum P(closed|u, x')P(x') \\ &= P(closed|u, open)P(open) \\ &\quad + P(closed|u, closed)P(closed) \\ &= \frac{9}{10} * 0.8 + \frac{1}{1} * 0.2 = 0.92 \end{aligned}$$

所以，执行一次关门动作后，门开着的概率变为了0.08.

## (四). 贝叶斯滤波算法

### 4.1 算法设定

由上述推导和示例，我们可以给出贝叶斯滤波的算法，算法的输入输出设定如下。

1. 系统输入

1. 1到 $t$ 时刻的状态观测和动作： $d_t = \{u_1, z_1 \dots, u_t, z_t\}$

2. 观测模型:  $P(z|x)$
3. 动作的状态转移模型:  $P(x|u, x')$
4. 系统状态的先验概率分布  $P(x)$ .

## 2. 期望输出

1. 计算状态的后延概率, 称为状态的**置信概率**:  $Bel(x_t) = P(x_t|u_1, z_1, \dots, u_t, z_t)$

## 4.2 算法基本假设

贝叶斯滤波的基本假设:

1. Markov性假设:  $t$ 时刻的状态由  $t-1$ 时刻的状态和  $t$ 时刻的动作决定。  $t$ 时刻的观测仅同  $t$ 时刻的状态相关, 如图4所示:




图4. Markov模型

$$p(z_t|x_{0:t}, z_{1:t}, u_{1:t}) = p(z_t|x_t)$$

$$p(x_t|x_{1:t-1}, z_{1:t}, u_{1:t}) = p(x_t|x_{t-1}, u_t)$$

2. 静态环境, 即对象周边的环境假设是不变的
3. 观测噪声、模型噪声等是相互独立的

## 4.3 Bayes滤波算法

基于上述设定和假设, 我们给出贝叶斯滤波算法的推导过程:

$$\begin{aligned}
 Bel(x_t) &= P(x_t|u_1, z_1, \dots, u_t, z_t) \\
 &= \eta P(z_t|x_t, u_1, z_1, \dots, u_t) P(x_t|u_1, z_1, \dots, u_t) <-\text{Bayes} \\
 &= \eta P(z_t|x_t) P(x_t|u_1, z_1, \dots, u_t) <-\text{Markov} \\
 &= \eta P(z_t|x_t) \int P(x_t|u_1, z_1, \dots, u_t, x_{t-1}) P(x_{t-1}|u_1, z_1, \dots, u_t) dx_{t-1} <-\text{TotalProb.} \\
 &= \eta P(z_t|x_t) \int P(x_t|u_t, x_{t-1}) P(x_{t-1}|u_1, z_1, \dots, u_t) dx_{t-1} <-\text{Markov} \\
 &= \eta P(z_t|x_t) \int P(x_t|u_t, x_{t-1}) P(x_{t-1}|u_1, z_1, \dots, z_{t-1}) dx_{t-1} <-\text{Markov} \\
 &= \eta P(z_t|x_t) \int P(x_t|u_t, x_{t-1}) Bel(x_{t-1}) dx_{t-1}
 \end{aligned}$$

其中第一步采用贝叶斯公式展开, 第二步使用Markov性质( $z_t$ 仅由 $x_t$ 决定); 第三步使用全概率公式对 $x_{t-1}$ 进行展开; 第四步继续使用Markov性质( $x_t$ 仅由 $x_{t-1}$ 和 $u_t$ 决定); 第五步继续使用Markov性质, 因为 $x_{t-1}$ 同 $u_t$ 无关, 最终得到 $Bel(x_t)$ 的递推公式。

可见递推公式中分为两个步骤,  $\int P(x_t|u_t, x_{t-1}) Bel(x_{t-1}) dx_{t-1}$ 部分是基于 $x_{t-1}, u_t$ 预测 $x_t$ 的状态;  $\eta P(z_t|x_t)$ 部分是基于观测 $z_t$ 更新状态 $x_t$ 。

## 4.3 Bayes滤波算法流程

所以, Bayes滤波的算法流程图如图5所示。如果 $d$ 是观测, 则进行一次状态更新, 如果 $d$ 是动作, 则进行一次状态预测。

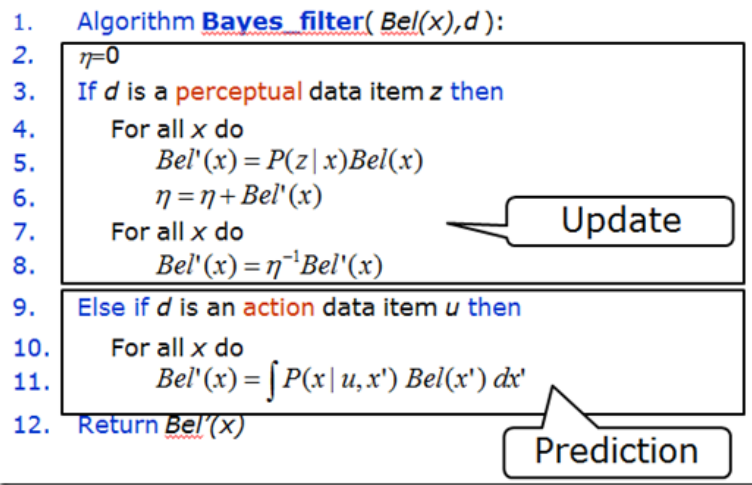


图5. Bayes滤波的算法流程

我们看到，在进行状态预测时，需要对所有可能的 $x'$ 状态进行遍历，使得基本的Bayes模型在计算上成本是较高的。

### 4.3 Bayes滤波算法的应用

Bayes滤波方法是很多实用算法的基础，例如：

- Kalman滤波
- 扩展Kalman滤波
- 信息滤波
- 粒子滤波

等，我们在下一节介绍Kalman滤波。

### 参考文献

[1]. Sebastian Thrun, Wolfram Burgard, Dieter Fox, Probabilistic Robotics, 2002, The MIT Press.

copyright ©2016 红山居士

更多资料: <http://in.ruc.edu.cn/pc2016>

博客园: <http://www.cnblogs.com/ycwang16/>

分类: 认知计算

标签: 机器人, 认知计算, 贝叶斯滤波, Bayes Filter, 贝叶斯公式, 条件概率, 条件推理



红山  
关注 - 0  
粉丝 - 11  
[+加关注](#)

3

0

« 上一篇: 写一个普通计算 (认知计算) 课程的博客

» 下一篇: (二). 细说Kalman滤波: The Kalman Filter

posted @ 2016-10-26 08:41 红山 阅读(5008) 评论(6) 编辑 收藏

### 评论列表

#1楼 2016-10-26 09:21 钻葛格

膜拜

支持(0) 反对(0)

---

#2楼[楼主 ] 2016-10-26 10:07 红山

@ IT民工-杰

写博客的经验不多，我刚把个人主页都去掉了。希望这个系列博客对理解这方面的知识有用处，我尽量把一些推导过程写详细。

支持(1) 反对(0)

---

#3楼 2016-10-26 10:59 ~ 扎克伯格

@ 王永才

好吧！大兄弟，我错怪你了

支持(0) 反对(0)

---

#4楼 2016-10-31 10:08 李奥霍克

我数学学的不是很好

2.4 贝叶斯递推公式

中，那个 $X|Z_1, \dots, Z_N$ 写成反向 $(Z_N, Z_{N-1})$ 的更好理解吧。

Markov属性是什么？为什么为causal knowledge的 $Z_1$ 到 $Z_{N-1}$ 去掉了，而分母的 $Z_N$ 还和 $Z_1$ 有关？

支持(0) 反对(0)

---

#5楼[楼主 ] 2016-11-10 09:04 红山

@ 李奥霍克

具体到这个公式中，Markov性是指当确定了 $n$ 时刻的状态 $x_n$ 后， $n$ 时刻的观测 $z_n$ ，就完全由 $x_n$ 决定，与 $x_{n-1}$ ， $z_1 \sim z_{n-1}$ 无关了。

而 $n$ 时刻的观测 $z_n$ 同前面的观测之间还是有关的。

支持(0) 反对(0)

---

#6楼 2017-11-18 19:16 StailLYD

机器人观测到门的距离 $Z$ 和门开关状态不是独立的吗？  
这个例子是不是有问题，还是我理解错误？

支持(0) 反对(0)

---

[刷新评论](#) [刷新页面](#) [返回顶部](#)

**注册用户登录后才能发表评论，请 [登录](#) 或 [注册](#)，访问网站首页。**

#### 相关博文：

- 朴素贝叶斯算法 & 应用实例
- 贝叶斯网引论 by 张连文
- 从贝叶斯到粒子滤波——Round 1
- 贝叶斯规则
- 粒子滤波

#### 最新新闻：

- 谷歌被控滥用用户定位工具 或在欧盟遭巨额罚款
- 亚马逊的医疗新项目：挖掘病人电子病历数据
- 300万英国乘客数据被泄露 优步被罚款38.5万英镑
- 赌输的金立：债权人想破产重整 供应商希望直接清算
- 公交司机吐槽银隆新能源客车：续航弱 设计不够精致
- » [更多新闻...](#)